


CS336 Lecture 17: 对齐与多模态

Alignment – Multimodality

标准中文图文课程笔记



频道: Stanford Online 发布日期: 2026-06-04

时长: 01:17:39 视频: <https://youtu.be/26FtD08Zp0U>

阅读方式: 本笔记将课程概念、公式、算法和工程边界重组为可独立阅读的教材。

目录

1 学习地图：Transformer 如何看见世界	3
1.1 本章小结	4
2 CLIP：从网页图文对中学习共享语义	5
2.1 对比学习目标	5
2.2 本章小结	5
3 数据处理与 Vision Transformer	6
3.1 本章小结	7
4 CLIP 的能力边界与零样本分类	8
4.1 本章小结	8
5 SigLIP：从批内 softmax 到成对 sigmoid	9
5.1 本章小结	10
6 LLaVA：视觉编码器、投影器与语言模型	11
6.1 本章小结	12
7 LLaVA-OneVision：多图、视频与 AnyRes	13
7.1 本章小结	14
8 统一 token 预算与数据课程	15
8.1 本章小结	16
9 模态迁移：从单图能力到多图和代理	17
9.1 本章小结	17
10 Qwen-VL 到 Qwen2-VL：动态分辨率与位置	18
10.1 本章小结	19
11 M-RoPE：时间、高度与宽度的位置编码	20
11.1 本章小结	20
12 Qwen3-VL：长上下文、损失平衡与 DeepStack	21
12.1 本章小结	22
13 实现机制：视觉 token 流水线	23

13.1 本章小结	23
14 Chameleon: 把图像变成可生成的离散 token	24
14.1 本章小结	25
15 统一生成的训练稳定性与取舍	26
15.1 本章小结	26
16 总结与延伸	27
16.1 延伸问题	27
16.2 最终结论	27

1 学习地图：Transformer 如何看见世界

语言模型把离散 token 序列映射为新 token 序列，但现实信息还包括图像、音频和视频。多模态系统需要回答两个不对称的问题：**如何把非文本输入编码为 Transformer 能消费的表达？如何生成非文本输出？**本讲主要讨论前者，并在末尾用 Chameleon 说明统一离散生成。




图 1: 现实数据的四类常见模态：文本、图像、音频与视频。




图 2: 多模态建模的两个基础问题：输入编码与非文本生成。

全讲主线

CLIP/SigLIP 学会视觉语义空间; LLaVA/Qwen-VL 把视觉 token 注入语言模型; Chameleon 将图像也离散化后统一自回归生成。三类方法的差别在于表示是连续还是离散、目标是理解还是生成。

1.1 本章小结

多模态并非简单增加一种文件格式，而是重新设计 token 化、位置、损失权重与数据配比。

2 CLIP：从网页图文对中学习共享语义

2.1 对比学习目标

批次中有 B 对图像与文本。图像编码器 f_I 、文本编码器 f_T 输出归一化向量

$$u_i = \frac{f_I(I_i)}{\|f_I(I_i)\|_2}, \quad v_j = \frac{f_T(T_j)}{\|f_T(T_j)\|_2}, \quad (1)$$

相似度为 $s_{ij} = u_i^\top v_j / \tau$ 。 I_i, T_j 分别是第 i 张图与第 j 段文本， τ 是温度。对称交叉熵为

$$\mathcal{L}_{\text{CLIP}} = \frac{1}{2} \left[-\frac{1}{B} \sum_i \log \frac{e^{s_{ii}}}{\sum_j e^{s_{ij}}} - \frac{1}{B} \sum_j \log \frac{e^{s_{jj}}}{\sum_i e^{s_{ij}}} \right]. \quad (2)$$

对角线是匹配对，其余同批样本自然充当负例。




图 3: CLIP 的批内相似度矩阵以及由类别文本实现零样本预测。

为什么网页噪声仍可用

单个图文对可能错误，但大规模数据让稳定共现模式累积为语义信号。清洗仍关键：OpenCLIP/LAION 流水线甚至用已有 CLIP 做过滤，形成“模型帮助构造下一代数据”的自举。

2.2 本章小结

CLIP 将分类标签换成自然语言，使开放词汇语义学习成为可能；代价是大批次、全局语义偏好与网页偏差。

3 数据处理与 Vision Transformer

CLIP 将任意长宽图像先缩放短边，再中心裁剪成固定方形。这符合当时 ImageNet 分类场景，却会损失边缘文字和细节；后续 AnyRes 正是为修复该限制。

```

63 Data:
64 • Searched for 500K queries, get ~20K (image, text) pairs per query
65 • Trained on 400M image-text pairs
66 • Didn't release the dataset
67 • Reproduced in OpenCLIP (using LAION-5B dataset, which used CLIP for filtering)[Cherti+ 2022]
68
69 Data processing [code]
70 • Images come in all resolutions (arbitrary W x H)
71 • Resize using bicubic interpolation so shorter side is 336 pixels
72 • Center crop (cuts off borders to get 336 x 336)
73
74 Vision encoder:
75 • Experimented with ResNet-50 and Vision Transformers [Dosovitskiy+ 2020]
76

```

图 4: CLIP 数据规模、开放复现与固定尺寸缩放/中心裁剪策略。

若图像大小为 $H \times W$ ，patch 边长为 P ，则 token 数

$$N_{\text{patch}} = \frac{H}{P} \frac{W}{P}. \quad (3)$$

每个 patch 展平并线性投影，加入位置编码与 class token 后进入 Transformer。 H, W 是高宽， P 是 patch 大小， N_{patch} 是视觉 token 数；分辨率翻倍会使 token 数约增四倍，注意力开销进一步呈平方增长。




图 5: ViT: 图像切块、线性投影、位置嵌入与 Transformer 编码器。

中心裁剪的隐含假设

它假设关键物体在中心且任务只需粗粒度分类。OCR、图表、文档与 GUI 场景通常要求保留边缘和局部高分辨率信息。

3.1 本章小结

ViT 让图像拥有 token 序列形式，但固定分辨率只是工程便利，不是多模态建模的最终答案。

4 CLIP 的能力边界与零样本分类

零样本分类把类别名写成提示模板，例如 “a photo of a dog”，编码后与图像向量比较。这将预训练中的匹配问题直接复用于分类，无需为每个新标签训练线性头。




图 6: 对比式目标比直接从图像生成文本更具数据与计算效率。

课程强调：CLIP 的表示最擅长由文本描述定义的**全局语义**，不一定保留像素级位置、计数或细粒度文字。生成文本的目标更强却更难优化；任务目标越复杂，不保证表示越高效。

表征用途决定目标

分类/检索重视语义对齐；OCR、检测与定位需要空间细节；图像生成还需要纹理和局部分布。一个统一向量很难同时服务所有层次。

4.1 本章小结

CLIP 奠定现代 VLM 的视觉语义底座，但“能匹配描述”不等于“能读出每个像素细节”。

5 SigLIP: 从批内 softmax 到成对 sigmoid

SigLIP 将每个图文对视作二分类。令 $z_{ij} \in \{+1, -1\}$ 表示是否匹配，则

$$\mathcal{L}_{\text{SigLIP}} = -\frac{1}{B^2} \sum_{i,j} \log \sigma(z_{ij}(u_i^\top v_j / \tau + b)), \quad (4)$$

其中 b 是偏置， σ 是 sigmoid。与 CLIP 的整行/整列 softmax 不同，每一对的损失可独立计算。

Summary:

- Encoding of images captures semantics given by (noisy) text
- Design decisions chosen based on image classification (not very fine-grained)
- Technical: requires large batch sizes, softmax operation over full batch

```
def siglip():
    SigLIP (Sigmoid Loss for Language Image Pre-Training) [Zhai+ 2023]
```

Objective:

- CLIP: multiclass classification for (text, image) versus (text, image') for all image'
- SigLIP: binary classification for (text, image) - aligned or not?

Algorithm 1 Sigmoid loss pseudo-implementation.

```
1 # img_emb : image model embedding [n, dim]
2 # txt_emb : text model embedding [n, dim]
3 # t_prime, b : learnable temperature and bias
```

图 7: SigLIP 将“匹配/不匹配”改写为独立二元分类。

Supports 100 languages

Efficiency:

- CLIP: 10 days on 256 TPUv3
- SigLIP: 5 days on 32 TPUv4 (lower FLOP/s than TPUv3) - much faster!

Batch size:

- Decouple batch size from loss
- Better than CLIP for <16K batch sizes

图 8: 多设备训练：文本块在设备间轮转即可累计跨设备图文对损失。

系统收益

损失与全局批次解耦，分布式实现不必一次保留完整相似度矩阵；文本分块轮转即可覆盖跨设备组合。更大批次仍存在临界点，课程给出的经验约为 32K。

5.1 本章小结

SigLIP 的关键不是换一个激活函数，而是改变归一化耦合结构，从而改善分布式训练与批次扩展。

6 LLaVA：视觉编码器、投影器与语言模型

基础架构由冻结的 CLIP ViT、线性投影 W 与 Vicuna 语言模型组成。若视觉特征 $X_v \in \mathbb{R}^{N_v \times d_v}$ ，语言模型维度为 d_l ，则

$$H_v = X_v W, \quad W \in \mathbb{R}^{d_v \times d_l}. \quad (5)$$

N_v 是视觉 token 数， H_v 与文本嵌入位于同一维度，可直接拼接进入自回归模型。

131 • MS COCO has images annotated with bounding boxes and Mechanical Turk captions
 132 • Prompt GPT-4 with captions or detected objects and generate questions or conversations
 133 • Pair generations with original images
 134 • 158K examples
 135

Context type 1: Captions
 A group of people standing outside of a black vehicle with various luggage. Luggage surrounds a vehicle in an underground parking area. People try to fit all of their luggage in an SUV. The sport utility vehicle is parked in the public garage, being packed for a trip. Some people with luggage near a van that is transporting it.

Context type 2: Boxes
 person: [0.681, 0.242, 0.774, 0.694], backpack: [0.184, 0.696, 0.485, 0.914], suitcase: ...<omitted>

Response type 1: conversation
 Question: What type of vehicle is featured in the image?
 Answer: The image features a black sport utility vehicle (SUV) ...<omitted>

Response type 2: detailed description
 The image is an underground parking area with a black sport utility vehicle (SUV) parked. There are three people in the scene, with one person standing closer to the left side of the vehicle, another person in the middle, and the third person on the right side. They are all working together to pack their luggage into the SUV for a trip. ...<omitted>

Response type 3: complex reasoning
 Question: What challenges do these people face?
 Answer: In the image, a group of people is standing outside a black SUV in a parking area, surrounded by various pieces of luggage, including suitcases and backpacks. They are facing the challenge of fitting all their luggage into the black SUV. There are multiple suitcases and backpacks to be packed, which suggests that the group has a significant amount of belongings ...<omitted>

图 9: 用 MS COCO 与 GPT-4 合成描述、对话和复杂推理数据。




图 10: LLaVA 的最小连接：视觉编码器经线性投影进入语言模型。

训练分两阶段：对齐阶段冻结两端只学 W ；指令微调阶段训练 W 与语言模型。前者像“翻译

视觉特征”，后者才让模型学会多轮问答与推理。

142

143

144

145

Training:

- Stage 1 (alignment): freeze vision encoder and language model, only train W
- Stage 2 (fine-tuning): freeze vision encoder and train W and language model

Visual input example, Extreme Ironing:



Source: <https://www.barnorama.com/wp-content/uploads/2016/12/03-Confusing-Pictures.jpg>

User

What is unusual about this image?

LLaVA

The unusual aspect of this image is a man ironing clothes on the back of a minivan or van. This is not a typical place to perform this activity, as one would usually iron clothes in a more stationary and safe location, such as a home, using a regular ironing board. The scene depicted in the image is peculiar as it involves a makeshift ironing setup on a vehicle, which can be both unsafe and unconventional. Additionally, it is not clear how the man is able to maintain balance and stability while ironing clothes in such an unstable environment.

User

[Start a new conversation, and clear the history]

LLaVA

What's happening in the scene?

The image depicts a man standing on top of a yellow SUV in a busy city street. He is holding a portable ladder, seemingly ironing clothes while standing on the vehicle. Around the scene, there are other cars, a traffic light, and a fire hydrant. Additionally, there are

图 11: 视觉推理样例：模型识别在汽车后部熨衣这一反常场景。

6.1 本章小结

LLaVA 证明很薄的投影器也能激活语言模型中的知识；大量能力仍来自预训练 LLM，而非视觉编码器本身。

7 LLaVA-OneVision: 多图、视频与 AnyRes

OneVision 使用 SigLIP、两层 MLP 投影器和 Qwen2，统一单图、多图与视频输入。核心难题是视觉 token 预算：单图可精看，多图每张降采样，视频每帧更粗。




图 12: OneVision 组件与单图、多图、视频三类输入。




图 13: AnyRes：全局缩略图提供上下文，局部切块保留 OCR 与细节。

设局部块视觉编码为 $E(C_k)$ ，全局缩略图为 $E(G)$ ，可写成

$$H_v = [E(G); E(C_1); \dots; E(C_K)]W. \quad (6)$$

K 是裁剪块数；若 token 超预算，再插值压缩。全局路径防止只见局部，局部路径避免高分辨率细节消失。

7.1 本章小结

AnyRes 将分辨率问题转为分层采样与 token 预算问题，是文档、图表和 GUI 理解的关键。

8 统一 token 预算与数据课程




图 14: 同一上下文预算下, 单图、多图、视频使用不同的采样密度。

视频的信息密度通常低于文本,连续帧又高度冗余;若逐帧高分辨率编码,训练会被长视频 token 主导。因此系统必须联合设计帧率、每帧分辨率与最大 token 数。




图 15: OneVision 的任务混合: 通用、文档/图表、OCR、推理等数据共同训练。




图 16: 从语言-图像对齐到高质量知识学习, 再到视觉指令微调。

从易到难的课程学习

先让投影器建立基本对齐，再引入高质量视觉知识，最后扩展到多图与视频指令。阶段化减少“视觉特征尚未可读时就要求复杂推理”的优化冲突。

8.1 本章小结

多模态系统的性能高度依赖数据混合和 token 计量；模型结构只是完整配方的一部分。

9 模态迁移：从单图能力到多图和代理

单图 OCR、图表理解可迁移到多图比较；图像中的圆圈提示可迁移到视频跨帧目标；GUI 截图数据又能支持代理按步骤执行操作。这种迁移并非零成本，仍需足够覆盖的任务混合。




图 17: 多图 GUI 理解：模型根据连续手机界面恢复操作序列。

监督任务多样性带来的组合能力

每个任务看似专门，但共享的视觉定位、文字识别与语言推理部件可以重组。评测时应区分真正组合泛化与训练集模板复现。

9.1 本章小结

模态迁移来自共享表示与任务覆盖；“一个模型支持多种输入”并不自动等于跨模态泛化。

10 Qwen-VL 到 Qwen2-VL：动态分辨率与位置

早期 Qwen-VL 使用 OpenCLIP 视觉编码器、跨注意力适配器与语言模型，并按预训练、多任务预训练、监督微调三阶段训练。




图 18: Qwen-VL 三阶段：先视觉/适配器，再多任务，最后冻结 ViT 做监督微调。

Qwen2-VL 引入原生动态分辨率：每个 224×224 块经过 ViT，再把 2×2 邻域合并为一个 token，以控制上下文长度。





图 19: Qwen2-VL 将不同分辨率图像与视频映射到可变长度视觉 token。

10.1 本章小结

动态分辨率不再强制所有图像消耗相同 token，使视觉计算与实际内容尺寸更匹配。


11 M-RoPE: 时间、高度与宽度的位置编码

标准 RoPE 对一维序列位置 p 施加二维旋转。多模态 RoPE 将位置拆成时间 t 、高度 h 、宽度 w ，并把各轴频率交错分配，避免某一轴只获得低频或高频维度。




- Key: dynamic resolution to handle varying resolutions
- Each 224 x 224 patch encoded with ViT/14, compress every 2x2 => 66 tokens
- Video: sample 2 frames/sec, max 16384 tokens

Multimodal Rotary Position Embedding (MRoPE):



This video features a dog, specifically a Shiba

Multimodal Rotary Position Embedding (M-RoPE)



Initialize LM with Qwen2 and vision encoder from DFN [Fang+ 2023]

Training (similar to Qwen-VL):

图 20: M-RoPE 为视频时间与二维空间建立联合位置编码。

对第 r 个频率分量，抽象写为

$$\text{RoPE}_r(q; t, h, w) = R(\omega_r a_r) q_r, \quad a_r \in \{t, h, w\}. \quad (7)$$

R 是二维旋转矩阵， ω_r 是第 r 个频率， a_r 指交错分配到的轴。显式时间戳 token 又为真实秒数提供语义，弥补仅靠帧索引的不确定性。

11.1 本章小结

多模态位置编码既要描述序列顺序，也要保留二维空间和真实时间尺度。

12 Qwen3-VL: 长上下文、损失平衡与 DeepStack

Qwen3-VL 扩展到长上下文、Dense/MoE 语言模型与 SigLIP2 视觉编码器。长视频会贡献远多于短文本的 token，若直接按 token 平均，视频样本将支配梯度。

41

42

43

44

45

46

47

48

49

50

51

52

53

54

55

56

4

- Qwen-3 models (dense and MoE models up to 235B-A22B)
- Long context understanding (256K)

Vision encoder:

- SigLIP-2 (same architecture as SigLIP) [Tschannen+ 2025]
- Interleaved MRoPE: distribute all axes (temporal, width, height) to low- and high-frequency bar ... [t w h t w h t w h t w h] rather than [t t t t w w w w h h h h]
- Add explicit video timestamps (as separate tokens rather in positional embeddings)
- Square-root-normalized per-token loss: balance text and multimodal data (video examples are l want to dominate)

Adapter:

- DeepStack: cross-layer fusion to inject visual information into multiple layers [Meng+ 2024]

Training:

- Pre-training has 4 stages (train adapter, train all parameters on 8K, 32K, 256K lengths)

Stage	Objective	Training	Token Budget	Sequence Length
S0	Vision-Language Alignment	Merger	67B	8 192

图 21: Qwen3-VL 的平方根归一化逐 token 损失用于平衡长短样本与不同模态。

一种结构化表达为

$$\mathcal{L} = \frac{1}{\sum_i \sqrt{n_i}} \sum_i \frac{1}{\sqrt{n_i}} \sum_{t=1}^{n_i} \ell_{it}, \quad (8)$$

n_i 是第 i 个样本 token 数, ℓ_{it} 是 token 损失。与按 token 总数归一化相比, 样本权重随长度次线性增长。

41

42

43

44

45

46

47

48

49

50

51

52

53

54

55

56

- Qwen-3 models (dense and MoE models up to 235B-A22B)
- Long context understanding (256K)

Vision encoder:

- SigLIP-2 (same architecture as SigLIP) [Tschannen+ 2025]
- Interleaved MRoPE: distribute all axes (temporal, width, height) to low- and high-frequency bar ... [t w h t w h t w h t w h] rather than [t t t w w w h h h h]
- Add explicit video timestamps (as separate tokens rather in positional embeddings)
- Square-root-normalized per-token loss: balance text and multimodal data (video examples are l want to dominate)

Adapter:

- DeepStack: cross-layer fusion to inject visual information into multiple layers [Meng+ 2024]

Training:

- Pre-training has 4 stages (train adapter, train all parameters on 8K, 32K, 256K lengths)

Stage	Objective	Training	Token Budget	Sequence Length
S0	Vision-Language Alignment	Merge	67B	8 197

图 22: DeepStack 将视觉编码器中间层特征注入语言模型多个层级。




图 23: Qwen3-VL 总体结构：可变分辨率视觉输入、长序列与多层视觉注入。

12.1 本章小结

Qwen3-VL 的增益来自一组小而关键的工程决策：模态损失平衡、多轴位置、显式时间和跨层视觉融合。

13 实现机制：视觉 token 流水线

Listing 1: AnyRes 视觉 token 的最小伪代码

```
1 def encode_anyres(image, vision_encoder, projector,
2                   crop_size=336, max_tokens=4096):
3     global_view = resize_keep_aspect(image, crop_size)
4     crops = tile_image(image, crop_size=crop_size)
5     features = [vision_encoder(global_view)]
6     features += [vision_encoder(crop) for crop in crops]
7     tokens = projector(concat(features, dim=0))
8     if len(tokens) > max_tokens:
9         tokens = spatial_interpolate(tokens, max_tokens)
10    return tokens
11
12 def multimodal_sequence(text_ids, vision_tokens):
13     # Special boundaries keep modality spans identifiable.
14    return [IMG_START] + vision_tokens + [IMG_END] + embed(text_ids)
```

实现中最容易忽略的四点

保持裁剪块二维顺序；在拼接前后记录位置元数据；对每种模态设置独立 token 上限；数据加载与视频解码必须流水化，否则 GPU 会等待 I/O。

13.1 本章小结

模型公式很简洁，但真正系统需要在分辨率、上下文长度、I/O 与批处理之间保持可复现约束。

14 Chameleon：把图像变成可生成的离散 token

连续视觉编码器适合“看图后输出文本”，却不能直接由语言模型生成像素。Chameleon 选择统一离散词表：图像先经 VQ-VAE 压缩为索引序列，再与文本 token 交错自回归建模。




图 24: Chameleon 的选择：把所有模态都映射成离散 token。




图 25: VQ-VAE：连续潜表示量化到码本索引，再由解码器重建图像。

若编码器输出 $z_e(x)$ 、码本为 $\{e_k\}_{k=1}^K$ ，离散索引为

$$k^* = \arg \min_k \|z_e(x) - e_k\|_2^2, \quad z_q(x) = e_{k^*}. \quad (9)$$

K 是码本大小， k^* 是最近码字。课程示例将 512×512 图像编码为 1024 token，词表约 8192。

14.1 本章小结

离散化让统一自回归生成成为可能，但量化会丢失细节，OCR 等精细任务尤其敏感。

15 统一生成的训练稳定性与取舍

图像 token 熵高、文本 token 熵低，共同训练会造成范数增长和不稳定。课程提到 QK normalization 与 z-loss 等稳定化方法；数据配比同样重要。




图 26: Chameleon 的训练规模、稳定性修复与离散化性能代价。

理解与生成可能需要不同表示

理解任务常需要语义连续特征；生成任务需要保留细粒度局部分布。现代系统常用连续视觉编码器负责理解、扩散模型负责生成，而非强迫单一离散表示包办全部任务。

15.1 本章小结

统一 token 空间优雅但并非免费：高熵模态带来优化压力，量化带来信息损失，扩散模型则提供另一条生成路径。

16 总结与延伸

```

30 # Injecting image encodings into LLMs
31 llava()
32 llava_onevision()
33 qwen_vl()
34 qwen2_vl()
35 qwen3_vl()
36
37 # Towards Omni models
38 chameleon()
39
40 Summary:
41 • Frontier models are expected to be multimodal (natively multimodal, omni)
42 • Fundamental challenge: how to encode non-text modalities?
43 • Comprehension and generation might demand different things (semantics versus finer-grained
44 • Balance images + video (lower information density) and text for training stability
45 • Continuous encoders + Transformer + diffusion models for generation
46

```

图 27: 全讲总结：多模态输入编码、理解/生成差异、模态平衡与连续/离散路线。

一页记忆框架

CLIP：批内对比学习共享语义，适合零样本分类与检索。

SigLIP：成对 sigmoid 解耦批次归一化，分布式更自然。

LLaVA：视觉编码器+投影器+ LLM，先对齐再指令微调。

OneVision/Qwen-VL：AnyRes、动态 token、M-RoPE、跨层融合与数据课程。

Chameleon：VQ-VAE 离散图像 token，实现统一自回归生成但牺牲细节。

16.1 延伸问题

如何按信息密度自适应分配视频帧？视觉编码器与 LLM 应共同训练到何种程度？位置编码怎样支持小时级视频？连续理解表示与扩散生成如何共享世界知识？这些问题把模型结构、数据与系统效率连接起来。

16.2 最终结论

多模态模型并非“给 LLM 接一只眼睛”这么简单。真正的设计空间是：把每种信号压缩成什么 token、保留多少细节、如何定位、怎样加权，并用怎样的生成机制还原输出。